

Семинар 9.

Мультиколлинеарность: диагностика и последствия.

1. Известно, что выборочная корреляция между переменными X и Z равна 0.9.

- (a) Найдите коэффициенты VIF для X и Z в регрессии $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \varepsilon_i$.
- (b) В каких пределах могут лежать коэффициенты VIF для X и Z в регрессии $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \beta_4 W_i + \varepsilon_i$?

Решение:

- (a) Для модели $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \varepsilon_i$ коэффициент VIF (фактор инфляции дисперсии) для переменной X вычисляется как:

$$VIF_X = \frac{1}{1 - R_X^2}$$

где R_X^2 — коэффициент детерминации в регрессии X на Z (и константу). Аналогично для Z .

Поскольку между X и Z только одна корреляция, $R_X^2 = (r_{XZ})^2 = 0.9^2 = 0.81$.

Тогда:

$$VIF_X = \frac{1}{1 - 0.81} = \frac{1}{0.19} \approx 5.263$$

Аналогично, $VIF_Z = VIF_X \approx 5.263$.

- (b) Для модели $Y_i = \beta_1 + \beta_2 X_i + \beta_3 Z_i + \beta_4 W_i + \varepsilon_i$ коэффициент VIF_X вычисляется как:

$$VIF_X = \frac{1}{1 - R_X^2}$$

где R_X^2 — коэффициент детерминации в регрессии X на Z и W .

Известно, что $r_{XZ} = 0.9$. Корреляция X с W неизвестна, но R_X^2 может меняться в зависимости от связи W с X и Z .

- Минимальный VIF : Если W не коррелирует с X ($r_{XW} = 0$), то R_X^2 остаётся равным 0.81, и $VIF_{\min} \approx 5.263$.
- Максимальный VIF : Если W сильно коррелирует с X (например, $r_{XW} \approx 1$), то R_X^2 может стремиться к 1. В пределе $R_X^2 \rightarrow 1$, тогда $VIF \rightarrow \infty$.

Таким образом, пределы для VIF_X и VIF_Z :

$$VIF \in [5.263, +\infty)$$

2. Покажите, что при наличии высокой корреляции между показателями наблюдается высокая дисперсия оценки параметров.

Решение:

Прежде чем приступить непосредственно к решению задания, давайте сделаем дополнительное упражнение, цель которого — объяснить, что находится в обратной матрице кросс-произведений $(X^T X)^{-1}$.

Обозначим нашу матрицу $(X^T X)^{-1}$ как V . Она симметрична, $V^T = V$. По определению, $X^T X \cdot V = I$. Разобьём произведение на две части по-другому, $X^T \cdot XV = I$.

Заметим, что $X_* = XV$ — это матрица такого же размера, как X , $n \times k$. Что же собой представляют эти звезданутые иксы, X_* ?

Во-первых, $X_* = XV$, поэтому новые X_* — это линейные комбинации исходных X с весами из матрицы $V = (X^T X)^{-1}$. Например, $x_{1*} = v_{11}x_1 + v_{21}x_2 + \dots + v_{k1}x_k$.

Во-вторых, $X_*^T X_* = (XV)^T XV = V^T X^T XV = V = (X^T X)^{-1}$. Матрица кросс-произведений новых переменных является обратной к матрице кросс-произведений исходных переменных.

В частности, $v_{11} = x_{1*}^T x_{1*}$, а $v_{12} = v_{21} = x_{1*}^T x_{2*}$.

В-третьих, $X^T X_* = I$, например, новая переменная x_{1*} перпендикулярна всем старым переменным кроме x_1 . Ортогональность позволяет нам взглянуть на первую звезданутую переменную как на остаток в регрессии. Первая ничем не выделяется, просто индексов меньше будет.

$$x_{1*} = v_{11}x_1 + v_{21}x_2 + \dots + v_{k1}x_k$$

Изолируем x_1 слева, а всё остальное — перенесём вправо:

$$x_1 = -\frac{v_{21}}{v_{11}}x_2 - \frac{v_{31}}{v_{11}}x_3 - \dots - \frac{v_{k1}}{v_{11}}x_k + \frac{1}{v_{11}}x_{1*}$$

Мы только что заметили, что переменная x_{1*} перпендикулярна x_2, x_3, \dots, x_k , поэтому перед нами регрессия x_1 на все остальные переменные X_{-1} :

$$x_1 = \hat{\beta}_{12}x_2 + \hat{\beta}_{13}x_3 + \dots + \hat{\beta}_{1k}x_k + e_1$$

Здесь $e_1 = x_{1*}/v_{11}$ — это остаток от регрессии x_1 на x_2, \dots, x_k . И $\hat{\beta}_{12} = -v_{21}/v_{11} = -v_{12}/v_{11}$ — это оценка коэффициента в регрессии x_1 перед переменной x_2 .

Отсюда мы сразу видим, что $V = (X^T X)^{-1}$ — это матрица-мать всех регрессий!

Хочешь узнать коэффициент в регрессии x_1 на все остальные переменные перед x_7 ? В умe, $\hat{\beta}_{17} = -v_{17}/v_{11}$.

Найдём, чему равен RSS_1 в этой регрессии.

$$RSS_1 = e_1^T e_1 = x_{1*}^T x_{1*} / v_{11}^2 = v_{11} / v_{11}^2 = 1 / v_{11}.$$

Бинго! Ура, $v_{11} = 1 / RSS_1$. Заметим, что $x_{1*} = e_1 v_{11} = e_1 / RSS_1$. Типичный недиагональный элемент равен $v_{12} = -\hat{\beta}_{12} v_{11} = -\hat{\beta}_{12} / RSS_1$. И, наконец, матрицу-матерь всех регрессий для $k = 3$ в студию:

$$V = (X^T X)^{-1} = \begin{pmatrix} 1/RSS_1 & -\hat{\beta}_{12}/RSS_1 & -\hat{\beta}_{13}/RSS_1 \\ -\hat{\beta}_{21}/RSS_2 & 1/RSS_2 & -\hat{\beta}_{23}/RSS_2 \\ -\hat{\beta}_{31}/RSS_3 & -\hat{\beta}_{32}/RSS_3 & 1/RSS_3 \end{pmatrix}$$

Например, первая строка этой матрицы несёт всю информацию о регрессии x_1 на x_2 и x_3 .

В случае пары центрированных регрессоров вспомним, что R^2 одинаков в регрессии x_1 на x_2 и в обратной и равен $R^2 = \hat{\beta}_{12}\hat{\beta}_{21}$. Поэтому, $v_{12}^2 = v_{21}^2 = \hat{\beta}_{12}\hat{\beta}_{21} / (RSS_1 RSS_2) = R^2 / (RSS_1 RSS_2)$ и $V = (X^T X)^{-1}$ равна

$$\begin{pmatrix} 1/RSS_1 & -\hat{\beta}_{12}/RSS_1 \\ -\hat{\beta}_{21}/RSS_2 & 1/RSS_2 \end{pmatrix} = \begin{pmatrix} \frac{1}{RSS_1} & -\frac{R}{\sqrt{RSS_1 RSS_2}} \\ -\frac{R}{\sqrt{RSS_1 RSS_2}} & \frac{1}{RSS_2} \end{pmatrix} = \\ = \frac{1}{1-R^2} \begin{pmatrix} \frac{1}{TSS_1} & -\frac{R}{\sqrt{TSS_1 TSS_2}} \\ -\frac{R}{\sqrt{TSS_1 TSS_2}} & \frac{1}{TSS_2} \end{pmatrix}.$$

Давайте вспомним, что ковариационная матрица вектора оценок коэффициентов исходной модели равна $\sigma^2 V$. Таким образом, последнее представление матрицы V позволило выделить в каждом элементе ковариационной матрицы множитель $\frac{1}{1-R^2}$, что представляет собой VIF . Очевидно теперь, что с ростом VIF растет дисперсия и ковариация оценок коэффициентов исходной модели, чтд.